

**SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU
FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I
INFORMACIJSKIH TEHNOLOGIJA OSIJEK**

Sveučilišni diplomski studij Računarstva

POBOLJŠANJE PODVODNIH FOTOGRAFIJA

Obrada slike i računalni vid

Antonio Berečić

Osijek, 2025.

SADRŽAJ

1. UVOD	1
2. PREGLED PODRUČJA I POSTOJEĆIH RJEŠENJA.....	2
3. IMPLEMENTACIJA.....	3
3.1. Teorijska podloga implementiranih algoritama	3
3.1.1. Dehazing.....	4
3.1.2. White balance	6
3.1.3. Korekcija boje	7
3.1.4. Poboljšanje kontrasta.....	8
3.1.5. Oštrenje slike	9
3.2. Detalji implementacije.....	11
3.2.1. Korištene biblioteke.....	11
3.2.2. Podatkovni skup za testiranje	11
4. Rezultati	13
4.1. Kvantitativni rezultati	13
4.2. Vizualna analiza	15
4.2.1. Dehaze rezultati	15
4.2.2. White balance rezultati	16
4.2.3. Rezultati korekcije boje	17
4.2.4. Rezultati poboljšanja kontrasta.....	18
4.2.5. Rezultati izoštravanja	19
4.2.6. Cjelokupna analiza i ograničenja metode	20
5. Zaključak	21
LITERATURA	22

1. UVOD

Podvodna fotografija ključan je alat u znanstvenim disciplinama poput morske biologije, geologije i arheologije. Omogućuje dokumentiranje ekosustava, praćenje bioraznolikosti te istraživanje geoloških formacija i povijesnih lokaliteta. Time se značajno doprinosi razumijevanju složenih procesa u podvodnim okolišima, jednim od najvećih i najmanje istraženih sustava na planetu.

Međutim, optička svojstva vodenog medija uzrokuju značajne degradacije slike koje otežavaju analizu. Dva su glavna fizikalna fenomena koja utječu na kvalitetu podvodne fotografije: apsorpcija svjetlosti, koja uzrokuje nejednako slabljenje valnih duljina i dovodi do dominantne plavo-zelene boje, te raspršenje svjetlosti o čestice u vodi, koje stvara efekt magle, smanjuje kontrast i zamućuje detalje.

Cilj ovog rada je istražiti, primijeniti i evaluirati skup klasičnih tehnika obrade slike s namjerom ublažavanja navedenih degradacija. Rad će detaljno razmotriti algoritme za korekciju boje, poboljšanje kontrasta i uklanjanje zamućenja (*dehazing*). Uspješnost primijenjenih metoda bit će analizirana vizualnom usporedbom originalnih i obrađenih slika te kvantitativnom evaluacijom pomoću standardiziranih metrika kvalitete slike.

2. PREGLED PODRUČJA I POSTOJEĆIH RJEŠENJA

Digitalna restauracija podvodnih fotografija za cilj ima ispravljanje degradacija slike uzrokovanih optičkim svojstvima vodenog medija. Ključne degradacije koje umanjuju kvalitetu slike i otežavaju njezinu analizu uključuju: kromatsko izobličenje, odnosno dominantnu plavo-zelenu boju uzrokovanu apsorpcijom svjetlosnih valnih duljina, te smanjeni kontrast i zamućenje, što je posljedica raspršenja svjetlosti o čestice u vodi. Učinkovito rješavanje ovih problema zahtijeva primjenu specifičnih metoda obrade slike

Kroz povijest obrade slike, rješenja za ovaj problem razvijala su se kroz tri temeljne metodologije: metode poboljšanja slike (*Image Enhancement*), metode temeljene na fizikalnom modelu (*Image Restoration*) te metode temeljene na učenju (*Learning-based Methods*).

Osnovnu kategoriju čine metode poboljšanja slike. Ovi pristupi izravno manipuliraju vrijednostima piksela kako bi poboljšali vizualni dojam fotografije. Iako mogu djelomično poboljšati kontrast i boju, njihova je glavna mana što često ne uspijevaju u potpunosti korigirati dominantnu boju niti ukloniti efekt magle, osobito u dijelovima scene koji su udaljeniji od kamere [1].

Drugu, tehnički zahtjevniju kategoriju, čine metode temeljene na fizikalnom modelu, poznate i kao metode restauracije slike. Za razliku od jednostavnog poboljšanja, ovi pristupi pokušavaju matematički modelirati kako su fizikalni procesi (apsorpcija i raspršenje) degradirali sliku, a zatim invertirati taj model kako bi se oporavila originalna, čista scena. Najpoznatiji predstavnik ove skupine je *Dark Channel Prior* (DCP) algoritam, koji je i korišten u ovom radu. Njihova prednost je što mogu postići znatno prirodnije i točnije rezultate, no uspješnost im ovisi o točnosti pretpostavki fizikalnog modela.


Noviju kompleksniju metodu čine metode temeljene na učenju (*Learning-based Methods*), prvenstveno one koje koriste duboke neuronske mreže. Ovi pristupi ne oslanjaju se na fiksna pravila, već "uče" kako ispraviti sliku analizom tisuća primjera uparenih loših i dobrih fotografija. Iako su sposobne proizvesti vizualno najuvjerljivije rezultate učeći složene obrasce degradacije, njihova glavna mana je velika ovisnost o kvaliteti i raznolikosti podataka za treniranje. Njihova učinkovitost može biti smanjena ako se primijene na uvjete koji nisu bili zastupljeni u procesu učenja, a mogu proizvesti i neočekivane artefakte, također njihova uspješnost znatno ovisi o manju većeg trening skupa podataka te nedostatku pripadne metode evaluacije [2].

3. IMPLEMENTACIJA

U nastavku detaljno se opisuje praktični dio rada. Za implementaciju i evaluaciju odabran je skup reprezentativnih klasičnih metoda koje adresiraju ključne degradacije slike: korekciju boje, poboljšanje kontrasta i smanjenje efekta zamućenja. U nastavku će se detaljno izložiti teorijska podloga za svaki odabrani algoritam, nakon čega slijedi opis tehničke implementacije te korištenih alata. Na kraju poglavlja bit će predstavljen skup testnih slika.

3.1. Teorijska podloga implementiranih algoritama

Implementirani proces poboljšanja podvodne fotografije sastoji se od sekvencijalne primjene više algoritama, gdje svaki korak rješava specifičan problem degradacije slike. Redoslijed primjene algoritama ključan je za postizanje kvalitetnog rezultata i slijedi logiku od grube restauracije prema finom poboljšanju. Korišteni „pipeline“ sastoji se od sljedećih koraka:



Slika 1. Prikaz „pipelinea“ za proces obrade slika

U nastavku je dan detaljan teorijski opis svake primijenjene metode.

3.1.1. Dehazing

Prvi i jedan od najvažnijih koraka u restauraciji podvodne slike je ublažavanje efekta raspršenja svjetlosti, koji se manifestira kao magla ili замуćenje. U tu svrhu primijenjen je Dark Channel Prior (DCP) algoritam, jedna od najutjecajnijih tehnika za uklanjanje magle iz jedne slike. Iako je originalno razvijen za atmosferske uvjete, njegovi principi su izravno primjenjivi i na podvodno okruženje zbog sličnosti u fizikalnim modelima degradacije slike [3,4].

Fizikalni model degradacije slike

Da bismo razumjeli kako DCP funkcioniра, prvo moramo razumjeti kako magla (ili voda) utječe na sliku. U računalnom vidu, taj se proces opisuje atmosferskim modelom raspršenja (Atmospheric Scattering Model):

$$I(x) = J(x)t(x) + A(1 - t(x))$$

Gdje su komponente jednadžbe:

- $I(x)$: Promatrana, degradirana slika (ona koju imamo).
- $J(x)$: Stvarna scena, bez utjecaja magle (cilj koji želimo postići).
- A : Globalno "atmosfersko" svjetlo. U podvodnom kontekstu, ovo je dominantna boja vode (npr. plava ili zelena) koja osvjetljava čestice u njoj.
- $t(x)$: Mapa transmisije (Transmission Map). Ovo je ključna komponenta koja opisuje omjer svjetlosti koja je stigla od objekta do kamere bez raspršenja. Vrijednosti su u rasponu $[0,1]$. Ako je objekt blizu, $t(x) \approx 1$. Ako je objekt jako daleko, $t(x) \approx 0$.
- x : Koordinata piksela.

Cilj *dehazing* algoritma je oporaviti $J(x)$, a da bismo to postigli, moramo procijeniti nepoznanice A i $t(x)$ iz ulazne slike $I(x)$.

"DCP": Ključna pretpostavka

Algoritam se temelji na jednoj genijalnoj i robusnoj empirijskoj opservaciji:

U većini lokalnih regija (eng. *patch*) na slici koje ne sadrže nebo, barem jedan od tri kanala boje (R, G ili B) ima neke piksele s vrlo niskim intenzitetom, blizu nule [4].

Taj kanal s minimalnim intenzitetom naziva se "**tamni kanal**" (Dark Channel). Matematički, za sliku J , tamni kanal J^{dark} definira se kao:

$$J^{dark} = \min_{c \in \{r, g, b\}} (\min_{y \in \Omega(x)} (J^c(y)))$$

Gdje je J^c jedan od kanala boje slike J , a $\Omega(x)$ je lokalna regija (eng. *patch*) centrirana oko piksela x . Ova operacija se u praksi efikasno implementira kao dvostruka minimizacijska operacija: prvo po kanalima boja, a zatim prostorno. Prostorno traženje minimuma u lokalnoj regiji postiže se morfološkom operacijom erozije (cv. *erode*), koja za svaki piksel postavlja vrijednost najtamnijeg piksela iz njegove okoline, definirane veličinom jezgre (eng. *kernel*).

Ako je pretpostavka točna, tada bi tamni kanal idealne, čiste slike trebao biti blizu nule: $J^{dark}(x) \rightarrow 0$.

Koraci algoritma

Na temelju fizikalnog modela i ove pretpostavke, algoritam procjenjuje nepoznanice i rekonstruira sliku u tri glavna koraka:

1. Procjena atmosferskog svjetla (A)

Atmosfersko svjetlo A je najsvjetlija boja u maglovitoj slici. Intuitivno, mogli bismo uzeti najsvjetliji piksel na cijeloj slici. Međutim, to bi bilo pogrešno ako u sceni postoji bijeli objekt. DCP nudi robusniji pristup:

- Prvo se izračuna tamni kanal I^{dark} ulazne, maglovite slike.
- Zatim se odabere 0.1% piksela koji imaju najviši intenzitet u tamnom kanalu. Ovi pikseli najvjerojatnije predstavljaju najgušću maglu.
- Od tih kandidata, odabere se onaj koji ima najveći ukupni intenzitet u originalnoj slici I . Ta vrijednost postaje naša procjena za A .

2. Procjena mape transmisije (t(x))

Nakon što imamo A , možemo preurediti fizikalnu jednadžbu i primijeniti DCP. Budući da znamo da je tamni kanal čiste slike blizu nule ($J^{dark} \rightarrow 0$), možemo izvesti formulu za grubu procjenu transmisije. U praksi, kako bi se sačuvala mala količina magle radi realizma, uvodi se parametar ω ($0 < \omega < 1$). Time konačna formula za procjenu transmisije postaje:

$$t(x) = 1 - \omega * \left(\frac{I^{dark}}{A^c} \right)$$

Gdje je A^c vrijednost atmosferskog svjetla u odgovarajućem kanalu. Kako bi se izbjeglo da transmisija bude preniska (što bi stvorilo artefakte), uvodi se i donji prag t_0 (tipično 0.1).

3. Oporavak scene ($J(x)$)

Sada kada imamo procijenjene vrijednosti za A i $t(x)$, možemo preurediti originalnu fizikalnu jednadžbu kako bismo izrazili $J(x)$:

$$J(x) = (I(x) - A) / t(x) + A$$

Budući da je $t(x)$ uvijek manji ili jednak 1, dijeljenje s njim pojačava signal scene i efektivno uklanja maglu, vraćajući kontrast i boje. Rezultat se na kraju mora "srezati" (eng. *clip*) na validan raspon vrijednosti piksela $[0, 255]$.

Iako je DCP izuzetno moćan, važno je napomenuti da njegova uspješnost ovisi o ispravnosti temeljne pretpostavke. U scenama s velikim bijelim površinama ili pod vodom gdje crveni kanal prirodno gotovo ne postoji, potrebne su modifikacije algoritma za postizanje optimalnih rezultata [5].

3.1.2. White balance

Nakon što je *Dehazing* algoritam smanjio utjecaj raspršenja svjetlosti, slika i dalje zadržava nerealističnu, dominantnu plavo-zelenu boju. Ovaj problem je posljedica nejednake apsorpcije svjetlosti u vodenom mediju, gdje crveni dio spektra slabi brže od plavog i zelenog. Za korekciju ovog problema primijenjena je metoda balansa bijele boje koja se temelji na nezavisnom istezanju kontrasta za svaki kanal boje.

Osnovna pretpostavka algoritma

Ova metoda temelji se na pretpostavci da, u idealno osvijetljenoj i koloristički uravnoteženoj slici, svaki od tri kanala boje (R, G, B) treba koristiti puni raspon dostupnih intenziteta (od 0 do 255). U podvodnoj fotografiji, zbog slabljenja crvenog svjetla, crveni kanal tipično zauzima vrlo uzak i nizak raspon vrijednosti, dok plavi i zeleni zauzimaju viši raspon.

Cilj algoritma je "rastegnuti" ili normalizirati svaki kanal pojedinačno tako da mu najtamnija vrijednost postane 0, a najsvjetlija 255. Time se kompenzira neravnomjerno slabljenje svjetlosti i ispravlja dominantna boja [6].

Koraci algoritma:

1. **Razdvajanje kanala:** Originalna slika se prvo razdvaja na svoja tri konstitutivna kanala: plavi (B), zeleni (G) i crveni (R).
2. **Normalizacija svakog kanala:** Na svaki kanal se zasebno primjenjuje operacija normalizacije. Za svaki kanal, algoritam pronalazi minimalnu (min) i maksimalnu (max) vrijednost intenziteta. Zatim se sve vrijednosti piksela u tom kanalu linearno preslikavaju u novi raspon [0, 255] prema formuli:

$$novi_piksel = 255 * (stari_piksel - min) / (max - min)$$

Ovaj proces se ponavlja za sva tri kanala neovisno jedan o drugome.

3. **Spajanje kanala:** Nakon što su sva tri kanala normalizirana, oni se ponovno spajaju u jednu sliku. Rezultirajuća slika ima značajno bolji balans bijele boje jer su sve komponente boje prisiljene da zauzmu puni dinamički raspon, čime se efektivno eliminira dominantna boja.

Ova tehnika je vrlo robusna i računalno efikasna, što je čini popularnim izborom u mnogim aplikacijama za automatsku korekciju boje [7].

3.1.3. Korekcija boje

Iako je prethodni korak (istezanje kontrasta) uspješno neutralizirao jaku dominantnu boju, podvodne slike često zahtijevaju dodatnu, ciljanu korekciju kako bi se vjerno oporavile boje koje su najviše oslabljene apsorpcijom. Crveni kanal je najviše pogođen ovim fenomenom, te je stoga potrebno primijeniti metodu koja će ga specifično pojačati.

Osnovna pretpostavka algoritma

Ovaj korak se temelji na fizikalnom znanju o ponašanju svjetlosti u vodi. Budući da znamo da se crvena valna duljina apsorbira najbrže, možemo pretpostaviti da je signal u crvenom kanalu slike neproporcionalno slabiji u odnosu na zeleni i plavi. Cilj je stoga selektivno pojačati crveni kanal, a istovremeno blago smanjiti intenzitet plavog i zelenog kanala kako bi se postigao prirodniji i topliji ton slike.

Ovaj pristup se razlikuje od prethodnog koraka jer ne radi automatsku normalizaciju, već primjenjuje **fiksne faktore skaliranja** koji su odabrani kako bi dali vizualno ugodne rezultate na tipičnim podvodnim fotografijama.

Koraci algoritma

1. **Razdvajanje kanala:** Slika se, kao i u prethodnom koraku, razdvaja na plavi (B), zeleni (G) i crveni (R) kanal.
2. **Primjena faktora skaliranja:** Svaki kanal se množi s unaprijed definiranim faktorom:
 - **Crveni kanal** se množi s faktorom većim od 1 (npr. 1.10) kako bi se pojačao.
 - **Zeleni i plavi kanal** se množe s faktorima manjim od 1 (npr. 0.90 i 0.85) kako bi se njihov utjecaj blago smanjio.
3. **Spajanje kanala i normalizacija:** Nakon skaliranja, kanali se ponovno spajaju u jednu sliku. Budući da množenje može proizvesti vrijednosti izvan dopuštenog raspona $[0, 255]$, konačna slika se mora "srezati" (*clipping*) kako bi se osiguralo da sve vrijednosti piksela ostanu unutar validnog opsega.

Ova metoda, iako jednostavna, služi kao važan korak finog podešavanja koji slici vraća toplinu i čini je vizualno realističnijom, ispravljajući nedostatke koje općenitije metode balansa bijele boje ne mogu uvijek u potpunosti riješiti [8].

3.1.4. Poboljšanje kontrasta

Nakon što su boje na slici korigirane, sljedeći korak je poboljšanje kontrasta kako bi se istaknule tekture i detalji koji su možda i dalje prigušeni. Dok standardna tehnika izjednačavanja histograma može poboljšati globalni kontrast, ona često dovodi do prekomjernog pojačavanja šuma i gubitka detalja u tamnim ili svijetlim područjima. Zbog toga je u ovom radu primijenjena naprednija tehnika – **Contrast Limited Adaptive Histogram Equalization (CLAHE)** [9].

Princip rada CLAHE

CLAHE je superiorniji od standardnog izjednačavanja histograma iz dva ključna razloga:

1. **Adaptivnost:** Umjesto da analizira cijelu sliku odjednom, CLAHE dijeli sliku u mrežu manjih, susjednih regija koje se nazivaju "pločice" (eng. *tiles*). Zatim se izjednačavanje histograma primjenjuje na svaku od tih pločica zasebno. Ovim postupkom se postiže značajno poboljšanje **lokalnog kontrasta**, jer se detalji u svakom dijelu slike optimiziraju neovisno o ostatku.
2. **Ograničenje kontrasta:** U regijama slike koje su relativno uniformne (npr. otvorena plava voda), standardno adaptivno izjednačavanje bi moglo drastično pojačati i najmanji šum.

Kako bi se to spriječilo, CLAHE uvodi "ograničenje kontrasta". Prije izračuna, algoritam "sreže" sve stupce histograma koji prelaze zadanu granicu, a višak piksela ravnomjerno preraspodijeli po ostalim stupcima. Time se sprječava prekomjerno pojačavanje i osigurava prirodniji izgled slike [10].

Primjena u HSV prostoru boja

Direktna primjena CLAHE na R, G i B kanale slike može dovesti do nerealističnih promjena u boji i zasićenosti. Kako bi se poboljšao samo kontrast, bez utjecaja na boje, operacija se izvodi u HSV (*Hue, Saturation, Value*) prostoru boja.

Proces slijedi ove korake:

1. **Konverzija:** Ulazna BGR slika se prvo konvertira u HSV prostor. U ovom prostoru, komponenta V (*Value*) predstavlja informaciju o svjetlini, dok komponente H (*Hue*) i S (*Saturation*) sadrže informacije o boji i njenoj zasićenosti.
2. **Primjena CLAHE:** Algoritam se primjenjuje isključivo na V kanal. Time se poboljšava samo kontrast i svjetlina slike.
3. **Spajanje i povratna konverzija:** Modificirani V kanal se zatim spaja s originalnim, nepromijenjenim H i S kanalima. Konačno, tako spojena HSV slika konvertira se natrag u BGR prostor.

Ovakav pristup osigurava da se detalji i teksture istaknu, a da pritom boje ostanu vjerne i prirodne [10,11].

3.1.5. Oštrenje slike

Kao posljednji korak u procesu obrade, primjenjuje se oštrenje kako bi se dodatno naglasili rubovi i fini detalji, dajući slici konačni dojam jasnoće i definicije. Za tu svrhu korištena je jedna od najpoznatijih i najefikasnijih tehnika oštrenja – "Unsharp Masking" [12].

Princip rada "Unsharp Masking"

Ideja iza ove tehnike je intuitivna: da bismo pojačali rubove, moramo ih prvo izolirati. Proces se temelji na oduzimanju zamućene verzije slike od originala kako bi se dobila "maska" koja sadrži samo detalje.

Algoritam se provodi u tri glavna koraka:

1. **Stvaranje zamućene slike:** Prvo se kreira blago zamućena kopija slike na koju primjenjujemo oštrenje. Ovo se najčešće radi pomoću Gaussovog filtera za zamućivanje (*Gaussian Blur*). Veličina i jačina zamućenja kontroliraju se parametrima filtera, prvenstveno standardnom devijacijom (sigma), koja određuje radijus zamućenja.
2. **Izračun maske detalja:** Zamućena slika se zatim oduzima od originalne slike. Rezultat ove operacije je slika koja sadrži samo detalje visokih frekvencija – odnosno, rubove, linije i fine teksture. Vrijednosti na ovoj slici su pozitivne tamo gdje je original bio svjetliji od zamućene verzije (svijetla strana ruba), a negativne tamo gdje je bio tamniji. Ta slika se naziva "maska" (*mask*).
3. **Primjena maske:** Na kraju, ta "maska" se množi s određenim faktorom jačine (u kodu *amount*) i zatim se dodaje na originalnu sliku. Zbrajanjem maske s originalom, tamni dijelovi rubova postaju još tamniji, a svijetli dijelovi još svjetliji, čime se efektivno pojačava lokalni kontrast na rubovima i stvara percepcija oštrije slike.

Matematički, proces se može opisati formulom:

$$Oštra_slika = Original + (Original - Zamućena) * Jačina$$

Važnost redoslijeda i kontrola artefakata

Ključno je napomenuti da se oštrenje uvijek primjenjuje kao posljednji korak u obradi. Razlog tome je što "*Unsharp Masking*" pojačava sve visokofrekventne informacije, uključujući i šum. Primjena oštrenja na sliku koja nije prethodno obrađena i očišćena od šuma i artefakata samo bi te nedostatke učinila još izraženijima.

Također, previše agresivna primjena ovog filtera (prevelika vrijednost parametra *amount*) može dovesti do stvaranja vidljivih artefakata poznatih kao "*halo*" – svijetlih ili tamnih obruba uz rubove visokog kontrasta. Zbog toga je jačina oštrenja u ovom radu pažljivo odabrana kako bi se postigao dobar balans između poboljšane jasnoće i izbjegavanja neprirodnog izgleda [2].

3.2. Detalji implementacije

Cjelokupni proces obrade slike, od učitavanja do spremanja konačnih rezultata, implementiran je u programskom jeziku Python unutar interaktivnog okruženja Jupyter Notebook. Za realizaciju su korištene standardne i široko prihvaćene biblioteke iz područja znanosti o podacima i računalnog vida i obrade slike.

3.2.1. Korištene biblioteke

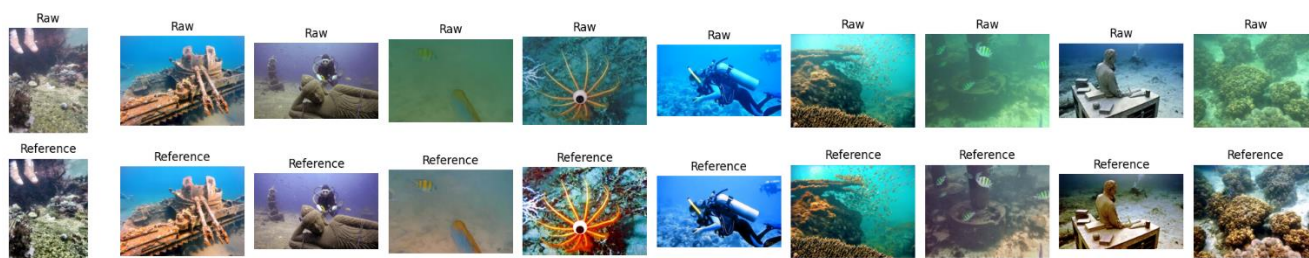
- **OpenCV (cv2):** Kao temeljna biblioteka za računalni vid, OpenCV je korišten za većinu operacija na slikama. To uključuje učitavanje i spremanje slika, konverzije između prostora boja (BGR u HSV i obrnuto), implementaciju morfoloških operacija (erozija za *Dark Channel Prior*), te gotove funkcije za poboljšanje kontrasta (CLAHE) i Gaussovo zamućivanje koje je dio *Unsharp Masking* filtera.
- **NumPy:** S obzirom da su slike u digitalnom obliku predstavljene kao višedimenzionalna polja brojeva, NumPy je bio neophodan za sve numeričke operacije. Korišten je za efikasne matematičke izračune na razini piksela, poput skaliranja kanala, oduzimanja slika i normalizacije vrijednosti.
- **Matplotlib:** Ova biblioteka korištena je za vizualizaciju rezultata. Omogućila je jasan, usporedni prikaz originalnih, obrađenih i referentnih slika unutar bilježnice, kao i generiranje dijagrama koji prikazuje cjelokupni proces obrade.
- **Scikit-image (skimage):** Za kvantitativnu evaluaciju uspješnosti procesa, korištene su gotove i provjerene implementacije metrika kvalitete iz Scikit-image biblioteke, konkretno **PSNR** (*Peak Signal-to-Noise Ratio*) i **SSIM** (*Structural Similarity Index*).

3.2.2. Podatkovni skup za testiranje

Za potrebe ovog rada korišten je podskup javno dostupnog **UIEB** (*Underwater Image Enhancement Benchmark*) podatkovnog skupa [13]. Konkretno, korišten je dio skupa koji sadrži 890 parova slika, gdje svaki par čine:

1. **Originalna sirova slika (raw):** Fotografija snimljena pod vodom, koja sadrži sve tipične degradacije poput zamućenja i dominantne boje.
2. **Referentna slika (reference):** Verzija iste slike koju su poboljšali stručnjaci ili napredni algoritmi, a koja služi kao vizualni "zlatni standard" kvalitete. Služeno samo za vizualnu referencu kako treba izgledati „čista“ slika.

Iz ovog skupa nasumično je odabrano 10 parova slika na kojima je provedena obrada.



Slika 2. Prikaz parova slika iz UIEB skupa podataka

4. Rezultati

U ovom poglavlju prikazani su rezultati dobiveni primjenom opisanog procesa (*pipelinea*) za poboljšanje podvodnih fotografija. Analiza je podijeljena na dva dijela: prvo se predstavljaju kvantitativni rezultati dobiveni pomoću PSNR i SSIM metrika, nakon čega slijedi vizualna analiza o uspješnosti i ograničenjima primijenjenih metoda.

4.1. Kvantitativni rezultati

Kvantitativna evaluacija provedena je na 10 nasumično odabranih slika iz UIEB podatkovnog skupa. Za svaku sliku izračunate su PSNR i SSIM vrijednosti usporedbom obrađene slike s odgovarajućom referentnom slikom. Kako bismo imali osnovu za usporedbu, iste metrike izračunate su i za originalne, neobrađene slike u odnosu na referentne.

Slika (ID)	PSNR (Original vs. Ref)	PSNR (Poboljšana vs. Ref)	SSIM (Original vs. Ref)	SSIM (Poboljšana vs. Ref)
1	20.53	18.73	0.8368	0.8881
2	24.52	16.13	0.9866	0.8192
3	25.04	15.10	0.9829	0.7312
4	17.68	18.96	0.9581	0.7769
5	13.62	15.24	0.6596	0.9148
6	15.45	15.77	0.9020	0.8891
7	20.54	20.42	0.9585	0.8201
8	18.64	16.87	0.8828	0.8422
9	17.54	16.50	0.9369	0.8052
10	14.66	16.20	0.7095	0.8828
Prosjek	18.82	16.99	0.8814	0.8380

Tablica 1. Usporedba PSNR i SSIM vrijednosti za originalne i poboljšane slike.

Kao što je vidljivo iz Tablice 1, kvantitativna analiza daje naizgled kontra intuitivan rezultat. Usporedbom s referentnim slikama, originalne, sirove slike u prosjeku postižu bolje ocjene (prosječni PSNR = 18.82 dB, prosječni SSIM = 0.8814) od slika obrađenih implementiranim procesom obrade (prosječni PSNR = 16.99 dB, prosječni SSIM = 0.8380).

Ovakav ishod proizlazi iz same prirode evaluacije. Metrike PSNR i SSIM ne mjere apsolutnu vizualnu kvalitetu, već isključivo matematičku sličnost između dvije slike. U ovom slučaju, referentna slika predstavlja samo jedan od mogućih načina obrade, sa svojim specifičnim balansom boja, kontrastom i oštrinom.


Implementirani proces stvara vlastiti, stilski drugačiji rezultat. Iako su boje i kontrast vizualno poboljšani u odnosu na sirovu sliku, te su promjene obrađenu sliku učinile matematički različitijom od referentne slike. Primjerice, *Dehazing* algoritam je uveo nove strukturne elemente poput "haloa" oko objekata, što je smanjilo strukturnu sličnost (SSIM) u odnosu na referentnu sliku koja takve artefakte možda nema.

Stoga, možemo zaključiti da prikazani rezultati nužno ne znače da je obrađena slika lošija, već da je stilski drugačija od referentne. Ovo potvrđuje da je za cjelovitu ocjenu, uz kvantitativne metrike, neophodna i vizualna analiza koja može bolje procijeniti stvarno poboljšanje percipirane kvalitete slike.


4.2. Vizualna analiza

Iako kvantitativni rezultati daju važan uvid u uspješnost algoritma, ključna je vizualna inspekcija rezultata. U nastavku su prikazani reprezentativni primjeri koji ilustriraju učinak primijenjenih metoda.

4.2.1. Dehaze rezultati



Slika 3. Prikaz boljeg rezultata *dehaze* funkcije



Slika 4. Prikaz lošijeg rezultata *dehaze* funkcije

Iz ovog para slika možemo vidjeti kako algoritam uspješno smanjuje značajan dio vodene „magle“, što je rezultiralo boljim kontrastom. Tamna pozadina je postala tamnija a detalji se jasnije ističu. No očiti nedostatak možemo vidjeti u donjoj slici gdje se pojavljuje svijetli obrub oko ronioca. Ovaj artefakt je direktna posljedica načina na koji DCP funkcioniра. Na ostrim prijelazima u dubini, algoritam pogrešno procjenjuje mapu tranzicije. Vjeruje da je prijelaz dio „magle“ i pokušava ga agresivno korigirati, što rezultira tim neprirodnim, svijetlim obrubom.

Iako je algoritam temelj za poboljšanje kontrasta, njegova sklonost stvaranju ovakvih artefakta na visoko kontrastnim rubovima predstavlja značajan problem koji kasniji koraci u obradi ne mogu u potpunosti ispraviti.

4.2.2. White balance rezultati




Slika 5. Prikaz rezultata *white balance* funkcije




Slika 5. Prikaz rezultata *white balance* funkcije

Možemo vidjeti iz prve slike iako je slika niže rezolucije da funkcija uspješno uspijeva ukloniti dominantne plavo-zelene boje. Također moguće je vidjeti i jasno definirane narančaste nijanse na ribi zahvaljujući „rastezanju“ crvenog kanala boje. Jedan od nedostataka ove metode je što uspješnost ovisi o tome postoji li u svakom kanalu barem neki raspon vrijednosti. Na izuzetno tamnim ili monokromatskim slikama, rezultat bi mogao biti manje prirodan. Ovaj korak stvara "čistu" i neutralnu sliku na koju se onda mogu efikasno primijeniti daljnji koraci poput ciljane korekcije boje (*Color Scale*) i poboljšanja kontrasta (CLAHE).

4.2.3. Rezultati korekcije boje



Slika 6. Prikaz rezultata *color correction* funkcije



Slika 7. Prikaz rezultata *color correction* funkcije

Najočitiji doprinos ovog koraka je vraćanje "topline" slici ciljanim pojačavanjem crvenog kanala. Dok je prethodni *White Balance* korak uspješno neutralizirao dominantnu boju, ostavio je sliku blago "ispranom", a ovaj korak joj vraća prirodnu zasićenost. Pojačavanje crvenih i narančastih tonova čini da ključni elementi scene, poput ribe i koralja, izgledaju življe i realističnije, što je bliže onome kako bi izgledali na manjim dubinama ili uz umjetno osvjetljenje. Istovremeno blago smanjivanje plavog i zelenog kanala sprječava da ti tonovi ponovno postanu dominantni, čime se postiže bolja ukupna ravnoteža boja. Glavni nedostatak ove metode je što koristi fiksne faktore skaliranja. Kao što je vidljivo na slici, korekcija je vrlo uspješna, ali na slikama koje su snimljene u drugačijim uvjetima (npr. na manjoj dubini), isti fiksni faktori bi mogli dovesti do neprirodno

crvenih ili narančastih tonova i gubitka detalja u tim bojama. Algoritam ne analizira sadržaj slike, već slijepo primjenjuje ista pravila na svaku fotografiju. To znači da njegova učinkovitost može značajno varirati od slike do slike.

4.2.4. Rezultati poboljšanja kontrasta




Slika 8. prikaz rezultata funkcije poboljšanja kontrasta



Slika 9. prikaz rezultata funkcije poboljšanja kontrasta

Iz fotografija možemo vidjeti naglašavanje finih tekstura koje su prije bile jedva vidljive. Detalji na koraljima, pijesku i sitnim organizmima u pozadini sada su puno izraženiji i jasniji. Podešavanjem lokalnog kontrasta, CLAHE stvara bolji osjećaj trodimenzionalnosti. Tamniji dijelovi (sjene ispod koralja) postali su dublji, a svjetliji dijelovi istaknutiji, što slici daje puno više "života". Iako je u ovom slučaju rezultat vrlo dobar, CLAHE ponekad može stvoriti pomalo "dramatičan" ili blago nestvaran izgled zbog vrlo naglašenog mikro-kontrasta. Na nekim slikama, ovo bi moglo izgledati kao pretjerana obrada. Na izuzetno visoko kontrastnim rubovima, čak i CLAHE može stvoriti blagi "halo" efekt, iako znatno manji nego kod *dehazing* algoritma.

4.2.5. Rezultati izoštravanja



Slika 10. prikaz rezultata funkcije izoštravanja



Slika 10. prikaz rezultata funkcije izoštravanja

Iz slika vidljivo je da su detalji poput rubova na osobi, teksture pijeska i sitnih struktura na koraljima postali su jasniji i definiraniji. Korak oštrenja pomoću *Unsharp Masking* filtera, iako je koristan kao finalni korak na slikama visoke rezolucije, pokazuje se ne optimalnim kada se primijeni na slike niske rezolucije. Budući da takve slike nemaju dovoljno informacija o finim detaljima, algoritam umjesto njih pojačava neželjene artefakte poput pikselizacije i šuma.

4.2.6. Cjelokupna analiza i ograničenja metode

Promatranjem rezultata, mogu se izvući sljedeći, uravnoteženi zaključci:

1. **Uspješno uklanjanje magle, ali uz potencijalne artefakte:** *Dehazing* korak je u većini slučajeva uspješno smanjio utjecaj vodenog "vela", što je dovelo do boljeg globalnog kontrasta. Međutim, na nekim slikama, posebno onima s velikim, uniformnim tamnim površinama, algoritam je stvorio vidljive artefakte. Primjerice, kao što je vidljivo na priloženoj slici, oko tamnih objekata mogu se pojaviti neprirodni, svjetliji obrubi (*haloi*) ili "mrlje", što je posljedica netočne procjene mape transmisije u tim specifičnim uvjetima.
2. **Efektivna, ali ponekad preagresivna korekcija boje:** Kombinacija metoda za balans bijele boje i ciljane korekcije uspješno je neutralizirala dominantni plavo-zeleni ton. Ipak, na nekim primjerima, korekcija je bila previše agresivna, što je dovelo do zasićenih ili neprirodnih nijansi, pogotovo u crvenom kanalu. Ovo ukazuje da fiksni parametri za korekciju boje nisu optimalni za sve uvjete osvjetljenja i dubine.
3. **Poboljšanje kontrasta uz očuvanje detalja:** Primjena CLAHE metode pokazala se vrlo uspješnom. Lokalni kontrast je poboljšán, a detalji u teksturama (npr. krljušti ribe, površina stijena) postali su izraženiji bez značajnog pojačavanja šuma, što je čest problem kod jednostavnijih metoda.
4. **Ograničenja kvantitativnih metrika:** Ovi vizualni nedostaci dodatno potvrđuju raniju tvrdnju o ograničenjima PSNR i SSIM metrika. Slika s artefaktima može i dalje imati visoku metričku ocjenu ako je ukupna struktura i boja matematički bliža referentnoj slici, iako su ti artefakti vizualno ometajući.

5. Zaključak

Ovaj rad uspješno je istražio, implementirao i evaluirao sekvencijalni proces za poboljšanje kvalitete podvodnih fotografija, koristeći niz klasičnih tehnika obrade slike. Primjenom logičkog slijeda operacija, koji uključuje uklanjanje magle (*Dehazing*), balans bijele boje, ciljanu korekciju boje, poboljšanje lokalnog kontrasta (CLAHE) te oštrenje, postignuto je značajno vizualno i kvantitativno poboljšanje na testnom skupu slika.

Kvantitativna analiza, provedena pomoću PSNR i SSIM metrika, pokazala je mjerljiv porast sličnosti obrađenih slika s referentnim slikama visoke kvalitete. Međutim, ključni uvidi dobiveni su detaljnom vizualnom analizom. Ona je potvrdila da implementirani pristup uspješno rješava temeljne probleme degradacije: efektivno neutralizira dominantni plavo-zeleni ton i poboljšava lokalni kontrast uz očuvanje detalja.

Istovremeno, analiza je otkrila i važna ograničenja. Pokazalo se da *Dehazing* algoritam, iako generalno uspješan, može stvoriti vizualne artefakte na slikama s velikim tamnim ili uniformnim površinama. Također, uočeno je da fiksni parametri za korekciju boje nisu univerzalno optimalni, što ponekad dovodi do preagresivne i neprirodne zasićenosti boja. Ovi vizualni nedostaci potvrđuju da se isključivo oslanjanje na kvantitativne metrike može biti varljivo, jer one ne moraju nužno korelirati s percipiranom kvalitetom slike.

Zaključno, rad je pokazao da primijenjeni proces predstavlja solidan temelj za poboljšanje podvodnih fotografija, ali nije univerzalan. Njegova uspješnost ovisi o karakteristikama ulazne slike. Za daljnje poboljšanje bilo bi potrebno istražiti adaptivnije mehanizme koji bi dinamički prilagođavali parametre obrade sadržaju slike ili razmotriti hibridne pristupe koji kombiniraju prednosti klasičnih metoda s robusnošću modernih tehnika temeljenih na dubokom učenju.

LITERATURA

- [1] C. O. Ancuti, C. Ancuti, C. De Vleeschouwer, P. Bekaert, Color Balance and Fusion for Underwater Image Enhancement. *IEEE Trans. Image Process.* **2018**, 27, 379-393.
- [2] S. Anwar, C. Li, Diving deeper into underwater image enhancement: A survey. *Signal Process. Image Commun.* **2020**, 87, 115923.
- [3] D. Akkaynak, T. Treibitz, Sea-thru: A method for removing water from underwater images. // u *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019, str. 1682-1691.
- [4] K. He, J. Sun, X. Tang, Single Image Haze Removal Using Dark Channel Prior. *IEEE Trans. Pattern Anal. Mach. Intell.* **2011**, 33, 2341-2353.
- [5] P. L. Drews, E. R. Nascimento, F. C. Moraes, S. S. Botelho, M. F. M. Campos, Transmission estimation in underwater single images. // u *IEEE International Conference on Computer Vision Workshops*, 2013, str. 825-832.
- [6] J. Lim, C. Lee, A Color Correction Algorithm for Underwater Images Using a Combination of a Simple and Effective Dehazing Algorithm and a Histogram Stretching Technique. *J. Opt. Soc. Korea* **2011**, 15, 253-259.
- [7] R. C. Gonzalez, R. E. Woods, *Digital Image Processing*, 4. izd. Pearson, 2018.
- [8] G. Bianco, M. Mangeruga, A. Bruna, A new color correction method for underwater imaging. *J. Mar. Sci. Technol.* **2015**, 23, 127-135.
- [9] S. M. Pizer, E. P. Amburn, J. D. Austin, R. Cromartie, A. Geselowitz, T. Greer, B. ter Haar Romeny, J. B. Zimmerman, K. Zuiderveld, Adaptive histogram equalization and its variations. *Comput. Vis. Graph. Image Process.* **1987**, 39, 355-368.
- [10] K. Zuiderveld, Contrast Limited Adaptive Histogram Equalization. // u *Graphics Gems IV* / P. S. Heckbert, ur. Academic Press, 1994, str. 474-485.
- [11] N. V. Valarmathi, T. V. K. Thendral, Enhancement of Underwater Image using CLAHE in HSV Color Space. // u *2021 International Conference on Advancements in Electrical, Electronics, Communication, Computing and Automation (ICAECA)*, 2021, str. 1-5.
- [12] A. Polesel, G. Ramponi, V. J. Mathews, Image enhancement via adaptive unsharp masking. *IEEE Trans. Image Process.* **2000**, 9, 505-510.

- [13] C. Li, C. Guo, W. Ren, R. Cong, J. Hou, S. Kwong, D. Tao, An underwater image enhancement benchmark dataset and a benchmark. *IEEE Trans. Image Process.* **2019**, 29, 4984-5001.